学习大模型和具身智能需要学习哪些内容，请给我详细的学习路线和学习课程（例如cs336等）

思考了 2m 59s

大模型（LLM）与具身智能（Embodied AI）完整学习路线

课程体系 · 数学基础 · 核心算法 · 论文阅读 · 项目实践 · 研究方向

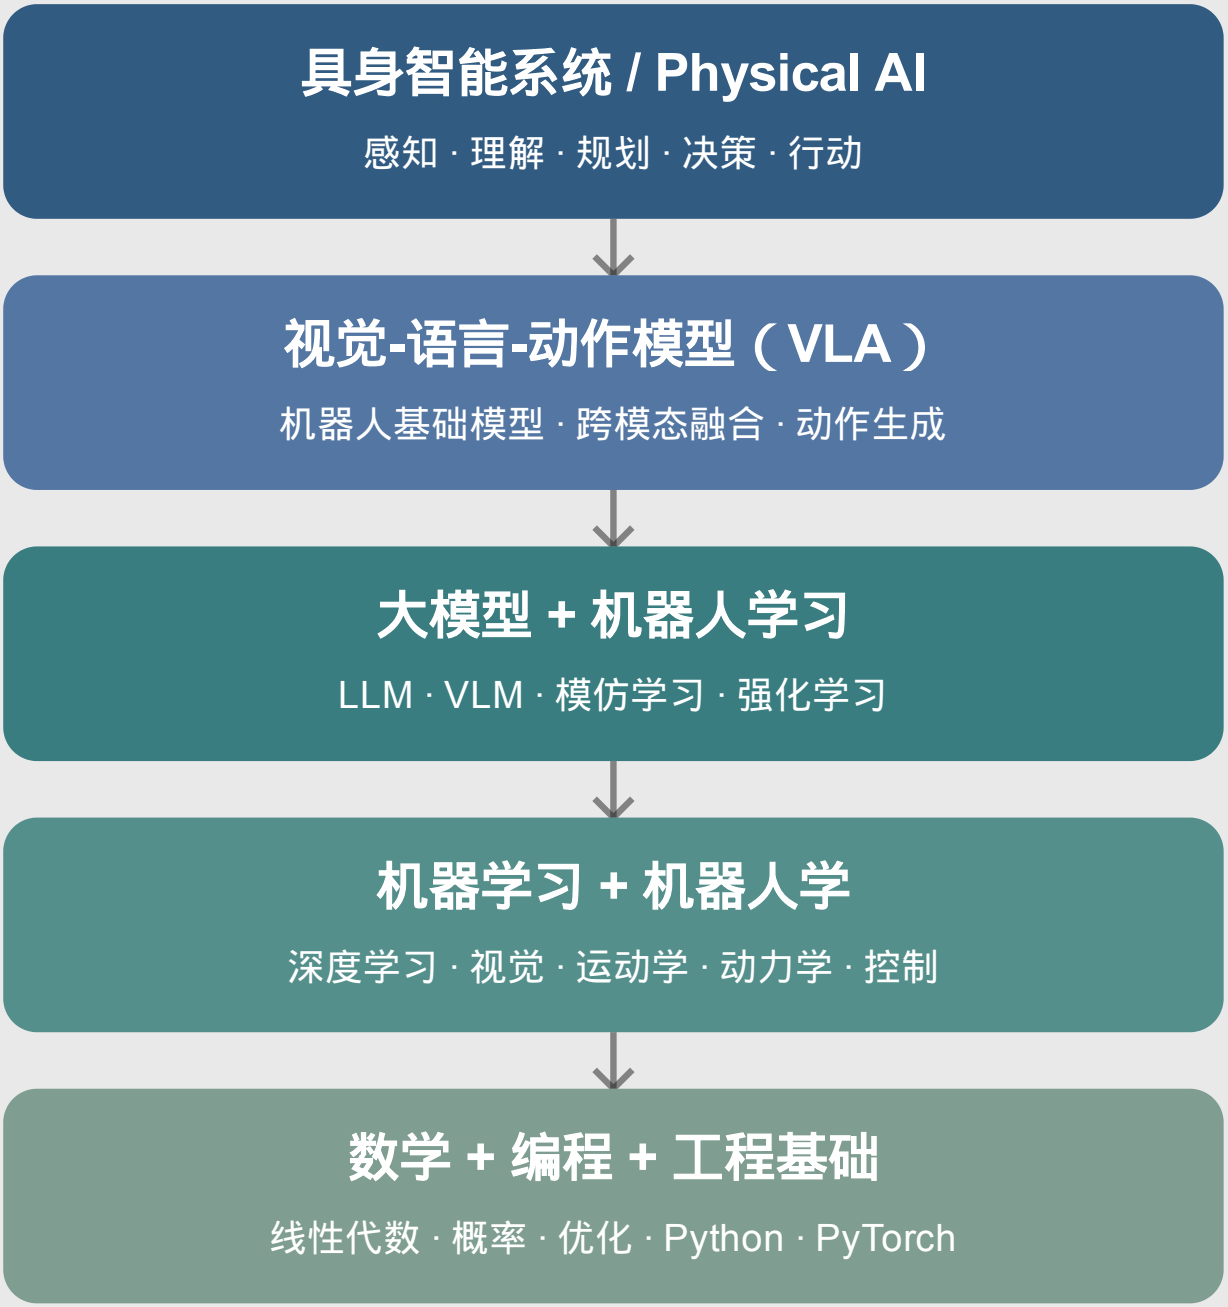
如果你的目标不仅是学会使用大模型，而是希望**真正理解大模型的原理、能够从零训练模型，并进一步开展具身智能方向的科研**，那么我建议采用一条将计算机科学、机器学习、机器人学和控制理论相结合的学习路线。

其中，斯坦福大学的 **CS336: Language Modeling from Scratch** 是非常值得重点学习的课程。目前已有 2026 年春季版，课程覆盖从模型架构、GPU 优化、预训练数据到后训练的完整流程。

Language Mod…

不过，CS336 主要解决的是“如何构建语言模型”，还不足以支撑完整的具身智能研究。

一、首先明确：需要掌握哪些知识？



学习知识结构图：从底层数学与软件能力，逐步走向具备物理交互能力的智能系统。

建议分成七个阶段：

阶段	主要内容	推荐核心课程
1. 数学与编程	Python、PyTorch、数学优化	CS229、Dive into Deep Learning
2. 深度学习	神经网络、CNN、Transformer	CS231N
3. 大语言模型	Tokenizer、预训练、微调、对齐	CS224N、CS336
4. 多模态大模型	计算机视觉、视觉语言模型	CS231N、CS25
5. 机器人学	运动学、动力学、轨迹规划	Modern Robotics、MIT Robotic Manipulation

6. 机器人学习	强化学习、模仿学习、Diffusion Policy	CS234、CS285
7. 具身智能研究	VLA、世界模型、Sim-to-Real	CS285、LeRobot、前沿论文

建议学习周期：12～18 个月，按照每周约 15～20 小时计算。如果已具备较好的数学、控制理论和 Python 基础，可以压缩部分基础课程，把更多时间投入 CS336、CS285 和具身智能论文复现。

二、第一阶段：数学、Python 与 PyTorch 基础

建议时间：第 1～2 个月

1. 数学基础

如果你已经学过高等数学、线性代数和控制理论，不需要把这些课程全部重新学习，但需要补齐机器学习特有的知识。

数学方向	必须掌握的知识	主要用途
线性代数	矩阵分解、特征值、SVD、投影、范数	Attention、表示学习
微积分	多元微分、链式法则、Jacobian、Hessian	反向传播、优化
概率统计	条件概率、贝叶斯推断、最大似然、KL 散度	生成模型、模型训练
优化理论	SGD、Adam、正则化、学习率调度	大模型参数学习
信息论	熵、交叉熵、互信息	语言建模、损失函数
随机过程	马尔可夫链、MDP、状态转移	强化学习、机器人决策
几何学	$SO(3)$、$SE(3)$、旋转矩阵、李代数	三维视觉、机器人运动学

特别建议真正理解以下公式，而不是只会调用 API。

交叉熵损失：

$$\mathcal{L} = -\sum_{i=1}^{N} y_i \log p_\theta(x_i)$$

梯度下降：

$$\theta_{t+1} = \theta_t - \eta \nabla_\theta \mathcal{L}$$

最大似然估计：

$$\theta^* = \arg\max_{\theta} \sum_{i=1}^{N} \log p_\theta(x_i)$$

其中交叉熵、概率分布、梯度计算这几项，会贯穿 LLM、VLM 和机器人学习。

2. Python 和深度学习编程

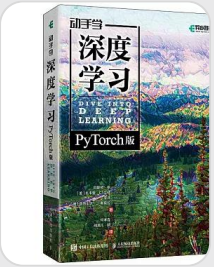
重点掌握：

- Python：函数、类、模块、类型标注、文件处理。
- NumPy：向量化计算、矩阵运算、广播机制。
- PyTorch：Tensor、Autograd、`nn.Module`、Dataset、DataLoader。
- GPU 编程：CUDA 基础、显存管理、混合精度。
- Linux 工具：Git、SSH、Conda/uv、Docker、日志与实验管理。

建议按这个顺序练习：

1. NumPy 实现线性回归、Logistic 回归和梯度下降。
2. 不使用自动微分，实现一个两层神经网络的反向传播。
3. 使用 PyTorch 实现 MLP、CNN，并完成训练和评估。
4. 自己写 Dataset、训练循环、检查点保存和恢复代码。

推荐课程



Dive into Deep Learning（动手学深度学习） ↗

优先学习

非常适合从理论过渡到代码。包含自动微分、神经网络、CNN、Attention、Transformer 和优化算法，还有中文版本与 PyTorch 实现。

Dive into Deep …

重点：第 2～8 章、第 11～13 章

Stanford CS229 — Machine Learning ↗

适合建立严谨的机器学习理论体系，尤其是最大似然估计、概率模型、偏差—方差分析与机器学习优化。2025 年课程也包含 LLM 专题。

CS229 Machin…

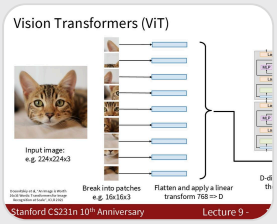
重点：监督学习、概率学习、优化、神经网络

本阶段完成标准： 能独立阅读并修改一个 PyTorch 神经网络训练项目，能解释损失函数、梯度更新、训练集与验证集的关系。

三、第二阶段：系统学习深度学习与 Transformer

建议时间：第 3～4 个月

核心课程：Stanford CS231N



CS231N — Deep Learning for Computer Vision ↗

必修

Stanford · Spring 2026

课程主页提供课程安排与课件。适合系统建立视觉深度学习知识，也是之后学习具身智能视觉感知模块的重要基础。

cs231n.stanfor…

重点学习以下内容：

模块	关键知识	必须掌握的模型
神经网络	MLP、Backpropagation	MLP
卷积网络	卷积、残差连接、归一化	ResNet
Attention	Query、Key、Value	Self-Attention
Transformer	多头注意力、位置编码	ViT、GPT
视觉表征	图像分类、目标检测、特征提取	ViT、视觉编码器
自监督学习	对比学习、掩码建模	CLIP、MAE

Transformer 是最重要的知识点

你必须能够从数学原理推导并从代码层面实现：

$$\boxed{\text{Attention}(Q,K,V)=\text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V}$$

需要理解：

- 为什么要除以 $\sqrt{d_k}$?
- 为什么要使用 Softmax?
- Self-Attention 与 Cross-Attention 有什么区别?
- 因果注意力掩码的作用是什么?
- 多头注意力为什么比单头更加灵活?
- Attention 的计算与显存开销为什么通常随序列长度呈平方增长?

- FlashAttention 为什么能提高执行效率？

实践任务： 使用纯 PyTorch 实现一个 Transformer Block，包括多头注意力、残差连接、LayerNorm/RMSNorm 和前馈网络。

四、第三阶段：大语言模型 LLM

建议时间：第 5～7 个月

这一阶段是大模型路线的核心。

课程 1：Stanford CS224N



CS224N — Natural Language Processing with Deep Learning ↗

理论基础

Stanford · Winter 2026

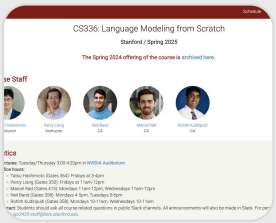
内容包括词向量、神经网络基础、自注意力、Transformer、大语言模型与评测，适合作为 CS336 的先修课程。

Natural Langua…

建议重点学习其四类作业：词向量、反向传播与神经网络、Self-Attention 与 Transformer、LLM Benchmarking and Evaluation。

Natural Langua…

课程 2：Stanford CS336



CS336 — Language Modeling from Scratch ↗

大模型核心课程

Stanford · Spring 2026

由 Percy Liang、Tatsunori Hashimoto 等授课，2026 年版本提供课程资料与视频入口。

Language Mod…

CS336 与普通的大模型应用课程最大的区别是：**它要求你从底层实现一个语言模型，而不只是调用已有模型。**

官方课程包含五组核心作业，下面是推荐的学习拆分。

Language Mod…

A1 **模型基础：从零实现 Transformer**

BPE Tokenizer、Embedding、RMSNorm、RoPE、Attention、SwiGLU、AdamW、训练循环。

成果：训练一个小型 GPT 语言模型。

A2 **系统优化：高性能模型训练**

GPU 性能分析、Triton、FlashAttention、分布式训练、显存优化。

成果：优化模型训练速度和显存占用。

A3 **Scaling Laws：模型规模规律**

参数量、训练 Token 数、计算量分配、规模规律拟合。

成果：分析模型大小与性能、计算成本的关系。

A4 **数据工程：构建预训练语料**

数据抓取与解析、过滤、去重、质量评估、数据混合。

成果：建立可复现的预训练数据流水线。

A5 **后训练：SFT 与强化学习**

监督微调、奖励设计、面向可验证结果的强化学习、模型对齐。

成果：将预训练语言模型进一步训练为能遵循指令、完成特定任务的模型。

2026 版还包含 Attention 替代架构、MoE、多模态等主题，可以在完成核心作业后进一步学习。

Language Mod…

推荐配套资源

- Andrej Karpathy — nanochat ↗：适合阅读一个覆盖 Tokenization、预训练、微调、评估与推理的简洁代码框架。其前身 nanoGPT 已被作者标记为旧版项目。

  GitHub +1

- Hugging Face LLM Course ↗：偏重 Transformers、Datasets、Tokenizers 等工具的工程实践。

  Hugging Face

- Hugging Face Agents Course（中文） ↗：适合补充语言模型的工具调用、规划和交互能力。

  Hugging Face

大模型必须掌握的整体训练过程

原始文本数据

数据清洗、去重、分词 Tokenization

↓

预训练 Pre-training

$$\mathcal{L}_{\mathrm{LM}} = -\sum_t \log p_\theta(x_t \mid x_{<t})$$

↓

监督微调 SFT

在指令与任务数据上继续训练

↓

偏好优化 / 强化学习

DPO、RLHF、可验证奖励等方法

↓

评测、推理与部署

准确性、鲁棒性、延迟、吞吐、资源成本

这个流程并非所有模型都必须完整采用，但它构成了理解现代 LLM 训练系统的重要框架。

到这一步，你应当至少能够实现一个千万级参数的小型 Transformer，掌握预训练和微调，并能够阅读大模型论文中的核心方法与算法。

五、第四阶段：多模态大模型 VLM

建议时间：第 8～9 个月

大语言模型主要处理文本，而具身智能系统必须理解摄像头图像、视频、空间关系以及自然语言指令。因此，需要从 LLM 进一步学习 VLM（Vision-Language Model）。

1. 核心知识

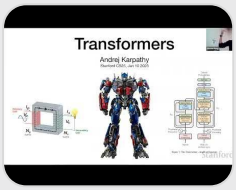
研究内容	需要掌握的技术
图像编码	CNN、ViT、Patch Embedding
图文对齐	CLIP、对比学习
跨模态融合	Cross-Attention、特征投影、视觉 Token

视觉指令理解	Image-Text Instruction Tuning
视频理解	时序建模、Video Transformer
三维感知	深度估计、点云、相机标定、空间表示
生成模型	VAE、Diffusion、Flow Matching
多模态推理	视觉问答、空间关系理解、任务规划

其中，我特别建议把 **Diffusion Models 和 Flow Matching** 作为重点。

原因是：它们不仅应用于图像生成，也广泛用于机器人连续动作的生成。

2. 推荐课程



CS25 — Transformers United ↗

Stanford · V6（2026）

研究型专题课程，覆盖 Transformer 在 LLM、多模态、机器人等领域的最新应用。适合了解科研方向，不适合作为零基础课程。

CS25

CS231N 视觉与深度学习进阶内容 ↗

重点学习视觉特征提取、Vision Transformer、视觉表示与生成方法。建议与论文阅读结合。

3. 这一阶段的三个实践项目

项目 A：自己实现 CLIP 的基本思想

输入图像 I 和文本 T，通过两个编码器得到特征：

$$z_I = f_\theta(I), \qquad z_T = g_\phi(T)$$

利用对比学习，使匹配图文的特征距离更近。

项目 B：实现简化版视觉语言模型

将 ViT 的视觉特征映射到语言模型的输入空间，尝试完成图像描述或简单视觉问答。

项目 C：实现条件 Diffusion Model

从基础扩散模型开始，逐步实现根据观测条件生成连续向量序列，为机器人动作生成做准备。

本阶段完成后，你应该能够回答一个核心问题：**如何把语言、图像和机器人状态表示成模型能够联合处理的数据?**

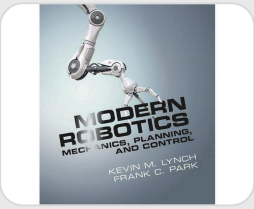
六、第五阶段：机器人学基础

建议时间：第 8～10 个月，可以与多模态学习并行

机器人学是具身智能与普通大模型最大的区别之一。

如果缺乏运动学、动力学以及执行器和传感器的知识，即使能够训练 VLA，也很难理解机器人的动作为什么有效、为什么失败。

推荐课程 1：Modern Robotics



Modern Robotics — Northwestern University ↗

机器人学基础首选

Kevin Lynch 与 Frank Park 的机器人学体系，有免费教学视频，覆盖刚体运动、运动学、动力学、轨迹规划、控制和操作。

Modern Robotics

建议重点学习：

- $SO(3)$、$SE(3)$、刚体变换。
- 正运动学与逆运动学。
- 机器人 Jacobian。
- 拉格朗日动力学。
- 轨迹生成和路径规划。
- 接触、抓取和力控制。

例如，你需要理解机械臂的动力学方程：

$$\boxed{M(q)\ddot{q} + C(q,\dot{q})\dot{q} + g(q) = \tau}$$

以及末端速度和关节速度之间的关系：

$$\dot{x} = J(q)\dot{q}$$

推荐课程 2：Stanford CS223A

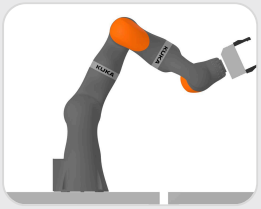
CS223A — Introduction to Robotics ↗

2026 年冬季版包括空间变换、机器人运动学、Jacobian、动力学、位置与力控制、视觉控制等内容。部分视频和材料依赖校内 Canvas 权限。

Introduction to ...

它与 Modern Robotics 内容有重叠，建议二选一作为主线，而不是完整学习两遍。

推荐课程 3：MIT Robotic Manipulation



MIT 6.4210 / 6.4212 — Robotic Manipulation ↗

具身智能重点课程

将感知、规划、运动学、动力学和机器人操作结合起来，包括 3D 几何、避障、任务与运动规划，以及学习方法。课程开放了学习资料。

Robotic Manipu...

对于具身智能方向，我认为 **MIT Robotic Manipulation 比单纯学习经典机器人控制课程更有针对性**，因为它将机器人如何感知环境、规划动作和操作物体串成了一套完整系统。

另外，MIT 的 Underactuated Robotics ↗ 非常适合深入研究动态系统、运动控制和机器人非线性动力学。

Fully-actuated ...

七、第六阶段：机器人学习 Robot Learning

建议时间：第 10～12 个月

机器人学习是具身智能的核心研究基础，主要解决机器人怎样从数据、示范和环境交互中获得操作能力。

这里需要掌握三种主要方法：

方法	核心思想	典型算法
模仿学习 IL	从专家示范中学习动作	BC、DAgger、ACT
强化学习 RL	通过环境反馈优化策略	PPO、SAC、TD3
生成式策略学习	学习动作序列的条件分布	Diffusion Policy、Flow Matching Policy

课程 1：Stanford CS234

CS234 — Reinforcement Learning ↗

2026 年冬季课程涵盖 MDP、Q-learning、策略梯度、模仿学习、离线强化学习、探索及相关理论，适合从基础开始建立强化学习知识。

Stanford Univer…

课程 2：UC Berkeley CS285



CS285 — Deep Reinforcement Learning ↗

具身智能核心课程

Sergey Levine 的课程。2026 年春季版不仅涉及策略梯度、Actor-Critic 和 Model-Based RL，还包括模仿学习、Offline RL 以及 LLM RL。

机器人与人工智…

对于希望从 LLM 研究转向机器人学习的人，CS285 的价值很高。

CS285 建议学习顺序

1. **Imitation Learning：** Behavior Cloning、DAgger、分布偏移。
2. **RL 基础：** MDP、Bellman 方程、价值函数。
3. **Policy Gradients：** REINFORCE、Actor-Critic、PPO。
4. **连续控制：** SAC、TD3 和连续动作空间。
5. **Model-Based RL：** 学习环境动力学与规划。
6. **Offline RL：** 从静态数据中学习策略。
7. **进阶：** 多任务学习、探索与强化学习理论。

其中，建议深入理解两个公式。

Bellman 最优方程：

$$Q^*(s,a) = \mathbb{E}\left[r + \gamma \max_{a'} Q^*(s',a') \mid s,a\right]$$

行为克隆的监督学习目标：

$$\mathcal{L}_{\text{BC}}(\theta) = \mathbb{E}_{(o,a)\sim\mathcal{D}}\left[\|\pi_\theta(o) - a\|^2\right]$$

第二个公式是使用均方误差训练确定性动作预测策略的一种基本形式。

在实际机器人操作中，策略通常还需要输出具有多峰特性的动作分布，这正是 ACT、Diffusion Policy 等方法的重要研究动机。

这一阶段的实践

先实现 Behavior Cloning，然后实现一个连续控制强化学习算法（如 SAC），最后对比两类方法在同一个仿真任务上的表现。

对于从控制理论转向机器学习的学习者，不一定要完整复现 CS285 所有算法，但必须掌握其理论逻辑与核心实验。

八、第七阶段：具身智能核心技术与 VLA

建议时间：第 12～15 个月

这一阶段开始真正进入具身智能研究。

1. 理解 VLA 的整体架构

VLA（Vision-Language-Action）模型的目标，是将视觉观测、语言任务和机器人状态映射到可执行动作。



这只是 VLA 的典型概念架构。不同模型可能将机器人状态放在不同模块中，动作预测也不一定采用独立的 Action Head。

2. 必须重点研究的三个算法

ACT（Action Chunking with Transformers）

一次预测未来一段连续动作，而不是只预测下一步动作。其重要思想是通过 Action Chunk 减轻模仿学习中的长时序误差累积。

tonyzhaozh.git…

Diffusion Policy

通过条件扩散过程生成机器人动作序列，适合表示复杂、多模态的连续动作分布。

Diffusion Policy

其简化的噪声预测训练目标可以写成：

$$\mathcal{L} = \mathbb{E}_{a^0,\epsilon,k,o}\left[\left\|\epsilon - \epsilon_\theta(a^k, k, o)\right\|^2\right]$$

其中 a^0 是真实动作序列，a^k 为添加噪声后的动作序列，o 为环境观测。

Flow Matching Policy

学习一个随时间变化的向量场，将简单分布连续映射到动作分布。

$$\frac{dx_t}{dt} = v_\theta(x_t, t \mid o)$$

这是理解一些现代机器人动作生成模型（例如 π_0）的重要基础。

arXiv

3. 重点阅读论文

建议按照以下顺序阅读：

顺序	论文	学习重点
1	Attention Is All You Need ↗	Transformer 基础
2	Diffusion Policy ↗	扩散动作生成
3	ACT / ALOHA ↗	Action Chunking、模仿学习
4	RT-2 ↗	VLM 如何转化为 VLA
5	Open X-Embodiment ↗	大规模机器人数据

6	OpenVLA ↗	开源 VLA 架构与训练
7	π_0 ↗	Flow Matching 与机器人基础模型

其中，RT-2 采用将机器人动作表示为 Token 的思路，OpenVLA 提供 VLA 训练与微调实现，而 π_0 使用基于视觉语言模型的流匹配动作生成架构。三者适合进行对比研究。

Google Dee… +2

4. 最推荐的实战框架：LeRobot



Hugging Face LeRobot ↗

重点实践

提供机器人数据处理、策略训练、模型评估与部署工具，支持 ACT、Diffusion Policy 和多种 VLA 模型。

GitHub

此外，还有配套的 Hugging Face Robotics Course ↗。它适合机器人学习入门，但截至本次查阅，后续强化学习、模仿学习、基础模型章节仍有未发布部分，因此不建议完全依赖这门课程。

Hugging Face

建议的实践顺序： 先使用现成机器人数据运行 ACT，再复现 Diffusion Policy，然后选一个较小的 VLA 模型进行微调。最后再尝试 OpenVLA 或 π_0 等较大模型。

九、必须学会使用哪些具身智能开发工具?

工具	主要用途	优先级
PyTorch ↗	深度学习训练	必须
Hugging Face ↗	模型、数据、微调	必须
LeRobot ↗	机器人策略学习	必须
MuJoCo ↗	机器人动力学仿真	必须
LIBERO ↗	机器人操作评测	推荐
ManiSkill ↗	操作技能仿真与训练	推荐
Isaac Lab ↗	大规模机器人学习仿真	推荐
ROS 2 ↗	机器人软件系统集成	实机阶段重点

openpi ↗	π 系列模型研究	研究进阶

Isaac Lab 可支持强化学习、模仿学习及 Sim-to-Real 工作流；LIBERO 更适合考察多任务机器人操作中的知识迁移与泛化。

Isaac Sim D… +1

我建议先使用仿真器完成算法复现，再考虑购买机械臂。没有实体机器人也完全可以开始研究。

十、完整的 18 个月学习时间表

下面提供一个可执行的学习安排。各月均以每周约 15～20 小时为参考。

M1–M2	**基础构建** 120–160 小时 Python、PyTorch、CS229 / D2L ✓ 完成 3 个基础神经网络项目	
M3–M4	**深度学习与 Transformer** 120–160 小时 CS231N、ViT、Self-Attention ✓ 手写完整 Transformer Block	
M5–M7	**大语言模型** 180–240 小时 CS224N、CS336、nanochat ✓ 完成小模型预训练与微调	
M8–M9	**视觉语言与生成模型** 120–160 小时 CS25、CLIP、VLM、Diffusion ✓ 训练小型图文模型和条件生成模型	
M10–M12	**机器人学与机器人学习** 180–240 小时 Modern Robotics、MIT Manipulation、CS285 ✓ 完成仿真环境中的 BC / RL 控制任务	

M13–M15

具身智能算法

180–240 小时

ACT、Diffusion Policy、OpenVLA、LeRobot

在 LIBERO 等任务上复现与评测

M16–M18

研究与创新

180–240 小时

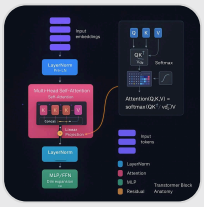
选择研究问题、做对照实验、消融实验

形成完整研究报告或论文初稿

这些时间是学习规划估算，而不是课程官方课时。如果作业实现难度较大，尤其是 CS336 和 CS285，可以适当延长。

十一、建议完成的 5 个代表性项目

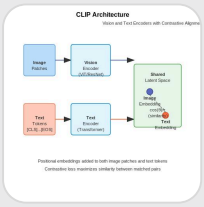
为了避免出现“课程看完很多，但不会科研和开发”的情况，我建议围绕以下五个项目积累能力。



项目 1：从零训练一个小语言模型

自己实现 Tokenizer、Transformer、优化器与训练循环，对比不同模型参数量和上下文长度对模型性能的影响。

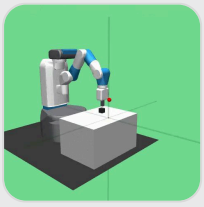
对应 CS336 · 大模型架构与训练



项目 2：构建小型视觉语言模型

训练图像编码器与文本表示之间的对齐模块，完成图文检索或视觉问答。

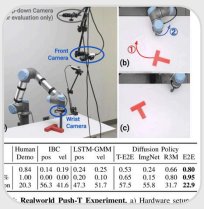
对应 CS231N、CS25 · 多模态表征



项目 3：仿真机器人模仿学习

搭建机械臂抓取与放置任务，采集演示数据，训练 BC 策略，并分析分布偏移与失败案例。

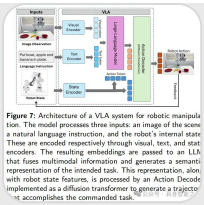
对应 CS285、MIT Manipulation



项目 4：复现 ACT 与 Diffusion Policy

在相同数据集和任务上比较两种算法的成功率、训练成本、动作平滑性和推理延迟。

对应具身智能核心算法 · 论文复现



项目 5：VLA 微调与泛化研究

使用 LeRobot、LIBERO 等工具，研究模型在不同语言指令、物体位置、视觉干扰和未见过场景中的泛化性能。

对应 OpenVLA、π_0 · 研究型项目

十二、如果未来想做科研，应该选择哪些方向？

下面是我认为比较值得重点考虑的研究分支，并不代表难度或发展前景的官方排名。

研究方向	代表问题	关键技术
机器人基础模型	一个模型能否控制多种机器人？	VLA、跨机器人数据学习
机器人模仿学习	如何通过少量示范学习复杂动作？	ACT、Diffusion Policy
世界模型	能否预测动作对未来环境的影响？	视频预测、潜在动力学
具身空间智能	模型如何理解三维几何和空间关系？	3D Vision、几何表征
Sim-to-Real	如何让仿真策略有效迁移到真实机器人？	域随机化、系统辨识
安全具身智能	怎样避免危险动作与任务失败？	安全约束、CBF、Lyapunov
多智能体具身系统	多机器人如何协作或竞争？	Multi-Agent RL、博弈论
具身智能规划	如何完成长时序复杂任务？	LLM Planning、分层策略

结合数学与控制方向，可以重点关注三个交叉领域

考虑到你此前研究过微分博弈、追逃问题，以及神经网络学习 Lyapunov 函数，我会特别建议关注以下三个方向。

方向 A：具身智能与安全控制（Safe Embodied AI）

研究 VLA 输出的动作如何满足系统的安全约束。

例如，VLA 预测动作 a_{VLA}，通过一个安全过滤层得到最终控制输入：

$$a^* = \arg\min_{a} \left\| a - a_{\mathrm{VLA}} \right\|^2$$

满足

$$\dot{h}(x,a) + \alpha(h(x)) \geq 0$$

在适当的系统模型和假设下，这类形式可以用于控制障碍函数（CBF）约束设计。

它将学习模型的表达能力与几何、控制理论的安全性质结合起来。

方向 B：具身智能与多智能体博弈

将微分博弈与多机器人交互相结合，例如：

- 多无人机追逃与协作。
- 基于视觉语言模型的多机器人任务决策。
- 多智能体策略的安全边界与获胜区域。
- 学习型决策与几何可达性分析。

这条路线能够利用已有的博弈论与几何分析基础，而不必完全转向纯大模型预训练研究。

方向 C：世界模型与动力学学习

学习机器人状态转移：

$$s_{t+1} = f_\theta(s_t, a_t)$$

再将动力学预测与规划、控制、安全性分析结合起来。

这个方向连接了机器学习、动力系统与机器人控制，适合希望在算法理论和具身智能之间寻找交叉点的研究者。

十三、课程优先级：如果时间有限，究竟先学什么？

前面列出的资源比较多，实际学习时不需要每门课程都从头到尾完整学完。

课程优先级筛选

LLM 方向 | 具身智能 | **两者兼顾**

只看高优先级课程

1	Dive into Deep Learning 深度学习基础 · 基础阶段	☆☆☆☆☆
2	Stanford CS336 大模型从零训练 · 核心阶段	☆☆☆☆☆
3	Stanford CS229 机器学习理论 · 基础阶段	☆☆☆☆☆
4	Stanford CS231N 计算机视觉 · 核心阶段	☆☆☆☆☆

5	Stanford CS224N NLP 与 Transformer · 核心阶段	☆☆☆☆☆
6	Berkeley CS285 深度强化与机器人学习 · 核心阶段	☆☆☆☆☆
7	Stanford CS234 强化学习基础 · 核心阶段	☆☆☆☆☆
8	Stanford CS25 前沿 Transformer 专题 · 研究进阶	☆☆☆☆☆
9	Modern Robotics 机器人学 · 核心阶段	☆☆☆☆☆
10	MIT Robotic Manipulation 机器人操作 · 核心阶段	☆☆☆☆☆
11	Hugging Face LeRobot 具身工程实践 · 核心阶段	☆☆☆☆☆

优先级是根据两类学习目标制定的学习建议，不是课程质量排名。基础课程可以根据已有知识跳过部分内容。

十四、最后给出一条最推荐的精简学习路线

如果希望兼顾大模型与具身智能科研，我会推荐下面这条主线：

D2L + CS229

补足深度学习与机器学习理论

↓

CS231N + CS224N

掌握视觉与 Transformer

↓

CS336

从零训练语言模型

↓

Modern Robotics + MIT Manipulation

建立机器人系统知识

↓



学习过程还有三个需要特别注意的地方。

第一，不必等到完全学完 CS336 再开始机器人学。LLM 与机器人学可以交叉推进，避免前期几个月完全没有接触具身智能。

第二，不必从一开始就训练几十亿参数模型。先在小模型上完整实现训练流程，比只会调用大型开源模型更有助于理解算法；真正做 VLA 时再借助预训练模型和微调技术。

第三，研究阶段应尽早围绕明确的问题开展可复现实验，例如“加入几何约束后，VLA 在未知障碍环境下的安全性是否提高”，而不只是不断复现新的模型。

如果把目标进一步明确为**能够阅读 ICLR、NeurIPS、CoRL、RSS 等会议中的具身智能论文，并具备开展独立研究的能力**，最值得投入时间的组合是：

CS336 + CS231N + MIT Robotic Manipulation + CS285 + LeRobot + VLA 论文复现。

这几项把大模型训练、视觉表示、机器人动力学、学习控制与具身智能实践连接起来，也最有利于进一步探索数学、几何控制与大模型结合的研究方向。

你喜欢这种个性吗?